

Chương 6

Hệ khuyến nghị

Chương 6 trình bày về hệ khuyến nghị, một trong những ứng dụng nổi bật của khoa học dữ liệu trong cách mạng công nghiệp lần thứ 4.

6.1 Giới thiệu chung

6.1.1 Hệ khuyến nghị là gì

Hệ khuyến nghị là một hệ thống dựa trên học máy giúp cho người dùng khám phá những sản phẩm và dịch vụ mới. Khi người dùng sử dụng các nền tảng thương mại điện tử trực tuyến, hệ khuyến nghị đang được sử dụng để hướng người dùng đến những sản phẩm mà họ muốn mua nhất dựa trên những dữ liệu về hành vi người dùng đã thu thập từ trước. Khi số lượng sản phẩm dịch vụ trong thế giới số càng ngày càng tăng, hệ khuyến nghị là một thành phần không thể thiếu vì người dùng thường bị choáng ngợp bởi số lượng lớn các sản phẩm, dịch vụ trên các nền tảng số. Người dùng cần sự giúp đỡ của hệ khuyến nghị để tìm được đúng sản phẩm mình cần tìm một cách tự nhiên, dẫn đến sự hài lòng cho họ, người bán sẽ bán được nhiều hàng hóa hơn, từ đó hoa hồng cho các nền tảng thương mại điện tử trực tuyến cũng tăng lên. Hệ khuyến nghị giống như một người bán hàng hiểu người mua hàng muốn gì dựa trên lịch sử mua hàng của khách hàng và thói quen mua sắm của họ.

Hiện nay, hệ khuyến nghị phổ biến đến nỗi người dùng sử dụng chúng hàng ngày mà thậm chí còn không nhận ra. Bởi vì người dùng không thể nào duyệt qua được tất cả các sản phẩm hoặc các nội dung trên website, hệ khuyến nghị đóng một vai trò quan trọng trong việc giúp cho người dùng có trải nghiệm tốt hơn, trong khi cũng

giúp cho người dùng khám phá ra những sản phẩm dịch vụ mới mà có thể người dùng quan tâm.

Một số ví dụ của hệ khuyến nghị trong các ứng dụng thực tế có thể kể đến hệ khuyến nghị của Amazon, Netflix gợi ý các bộ phim, chương trình TV; hệ khuyến nghị của Youtube gợi ý các videos mà người dùng quan tâm; hệ khuyến nghị của Spotify gợi ý các bài hát, bản nhạc mà người dùng có thể thích nghe; Facebook gợi ý tin cho người dùng và Google gợi ý các quảng cáo sản phẩm mà người dùng quan tâm.

Một trong những thành phần quan trọng nhất của bất kỳ một hệ khuyến nghị nào nêu trên là hàm khuyến nghị. Hàm này nhận đầu vào là thông tin từ người dùng và dự đoán xếp hạng (rating) mà người dùng này có thể gán cho các sản phẩm. Việc dự đoán được xếp hạng này trước khi người dùng đưa ra đánh giá xếp hạng của họ cho sản phẩm làm cho các hệ khuyến nghị trở thành một công cụ mạnh mẽ trong thực tế.

6.1.2 Hệ khuyến nghị hoạt động thế nào

Các hệ khuyến nghị hoạt động dựa trên nguyên tắc hiểu rõ các quan hệ của các thực thể trong hệ thống. Các quan hệ cung cấp cho hệ khuyến nghị những góc nhìn sâu sắc về bản chất của các hành vi mà người dùng thực hiện trên các nền tảng. Thông qua các quan hệ này, hệ khuyến nghị hiểu rõ về khách hàng khi họ có nhu cầu mua các sản phẩm. Có 3 loại quan hệ hay được sử dụng trong hệ khuyến nghị: (1) quan hệ giữa người dùng và sản phẩm; (2) quan hệ giữa sản phẩm và sản phẩm; và (3) quan hệ giữa người dùng và người dùng.

Mỗi quan hệ giữa người dùng và sản phẩm xuất hiện khi một số người dùng có cùng sở thích với một loại sản phẩm cụ thể nào đó mà họ cần. Ví dụ, một người chơi bóng đá có thể có sở thích mua các mặt hàng có liên quan đến bóng đá, do đó các trang thương mại điện tử sẽ xây dựng một mối quan hệ giữa người dùng và sản phẩm là người chơi và bóng đá. Trong khi đó, mối quan hệ giữa sản phẩm và sản phẩm xuất hiện khi các mặt hàng có tính chất tương tự nhau, về hình thức hoặc mô tả. Một số ví dụ bao gồm sách hoặc nhạc cùng thể loại, các món ăn từ cùng một nền ẩm thực hoặc các bài báo từ một sự kiện cụ thể. Mối quan hệ giữa người dùng và người dùng xuất hiện khi một số người dùng có sở thích tương tự đối với một sản phẩm hoặc dịch vụ cụ thể. Ví dụ bao gồm bạn bè chung, xuất thân tương tự, tuổi

tác tương tự,...

Các hệ khuyến nghị hoạt động đằng sau rất nhiều các nền tảng website lớn. Các website thương mại điện tử thường sử dụng hệ khuyến nghị để tăng sự gắn bó, yêu thích của khách hàng với nền tảng và tăng lượng giao dịch. Tuy nhiên, những gợi ý được tạo ra trên các nền tảng này phụ thuộc lớn vào chất lượng và số lượng dữ liệu họ có được. Do đó, việc xử lý một lượng lớn dữ liệu (thông tin) là tối quan trọng để xây dựng một hệ khuyến nghị tốt phục vụ cho nhu cầu của các nền tảng này.

Khi mua hàng hoặc tìm kiếm thứ gì đó trên Amazon, chúng ta có thể sẽ thấy những sản phẩm được gợi khuyến nghị dựa trên sở thích của chúng ta hoặc những kết quả hiển thị lên trang tìm kiếm. Hoặc khi đánh giá một chương trình TV hoặc một bộ phim trên nền tảng đánh giá phim trực tuyến IMDb, nền tảng này sẽ gợi ý những chương trình hoặc bộ phim khác dựa trên những chi tiết quan trọng như diễn viên, thể loại, cốt truyện, tóm tắt. Ví dụ như nếu bạn xem một bộ phim với thể loại phim tài liệu, trang web sẽ gợi ý cho bạn những bộ phim cùng thể loại tài liệu đó với xác suất bạn sẽ thích những bộ phim này và xem nó. Trong khi đó Facebook và Instagram sử dụng các hệ khuyến nghị với một quy mô lớn hơn để gợi ý bạn bè và các bài đăng của người khác trên newsfeed. Thông thường, người dùng sẽ thấy những mẫu tin tức tương tự nhau dồn dập trên newsfeed dựa trên những lượt yêu thích và những trang mà họ theo dõi, điều này cũng có thể làm cho việc gợi ý trở nên nhàm chán. Các nền tảng thường sẽ phải có thêm những thuật toán lọc thông minh dựa trên các tương tác thực tế của người dùng với các bài tin tức để đưa ra những gợi ý phù hợp hơn. Với cỗ máy tìm kiếm Google, mỗi lần chúng ta đăng nhập và tìm kiếm thứ gì đó, thông tin sẽ được ghi lại vào lịch sử tìm kiếm và sẽ gợi ý những sản phẩm dựa trên những tìm kiếm trước đó. Kết quả là, hơn 90% doanh thu của Google tới từ các hoạt động quảng cáo sản phẩm dựa trên lịch sử tìm kiếm của người dùng. Những kết quả tìm kiếm trả về cho người dùng cũng tính toán đến cả vị trí của người dùng tại thời điểm tìm kiếm.

Tóm lại, hệ khuyến nghị là một mảng khá rộng của học máy và có tuổi đời ít hơn so với các hệ phân loại vì Internet mới chỉ thực sự bùng nổ khoảng hai thập kỷ trở lại đây. Có hai thực thể chính trong Hệ gợi ý là users và items. Users là người dùng. Items là sản phẩm, ví dụ như các bộ phim, bài hát, cuốn sách, clip, hoặc cũng có thể là các users khác trong bài toán gợi ý kết bạn. Mục đích chính của các hệ khuyến nghị là dự đoán mức độ quan tâm của một người dùng tới một sản phẩm nào đó, qua

đó có chiến lược khuyến nghị phù hợp, tăng tính tương tác của người dùng với sản phẩm, làm tăng khả năng chuyển đổi từ gợi ý sang mua hàng.

6.2 Lọc dựa trên nội dung

Lọc dựa trên nội dung là một trong hai nhóm lớn của các hệ khuyến nghị. Lọc dựa trên nội dung đánh giá đặc tính của các sản phẩm được khuyến nghị. Ví dụ: Một người dùng xem rất nhiều bộ phim hành động, vậy thì gợi ý một bộ phim trong cơ sở dữ liệu có chung đặc tính *hành động* tới người dùng này, ví dụ phim *Fast and Furious*. Cách tiếp cận này yêu cầu việc sắp xếp các sản phẩm vào từng nhóm hoặc đi tìm đặc trưng của từng sản phẩm. Tuy nhiên, có những sản phẩm không có nhóm cụ thể và việc xác định nhóm hoặc đặc trưng của từng sản phẩm đôi khi là không thể thực hiện được.

6.2.1 Utility matrix

Như đã đề cập đến ở phần trước, có hai thực thể chính tồn tại ở trong các hệ khuyến nghị là người dùng và sản phẩm. Mỗi người dùng có mức độ quan tâm đến từng sản phẩm khác nhau. Mức độ quan tâm này, nếu đã được biết trước bằng một cách nào đó, được gán cho một giá trị tương ứng với mỗi cặp user-item. Giả sử mức độ quan tâm được đo đạc bằng giá trị mà người dùng đánh giá cho sản phẩm (rating). Tập hợp tất cả các ratings, bao gồm cả giá trị chưa biết cần phải dự đoán, tạo nên một ma trận gọi là utility matrix. Xét ví dụ sau:

Trong ví dụ này, có 4 người dùng P1, P2, P3, P4 và 5 bộ phim. Các ô có giá trị trong bảng thể hiện một người dùng đã đánh giá một bộ phim với điểm tương ứng từ 0 (không thích) tới 5 (rất thích). Các ô trống còn lại tương ứng với những bộ phim mà user chưa có đánh giá. Hệ khuyến nghị muốn đưa ra được gợi ý cho người dùng trên hệ thống cần phải dự đoán được giá trị trong các ô còn trống giá trị.

Trong ví dụ này có thể thấy có 2 thể loại phim khác nhau là phim *hành động* và phim *tình cảm*. Từ dữ liệu này, ta có thể có những gợi ý nhất định cho các user còn lại về những bộ phim tương ứng mà họ thích. Giả sử như hệ thống chỉ có những bộ phim thuộc 2 thể loại này, khi có một bộ phim mới, ta chỉ cần phân lớp nó vào thể loại nào, sau đó ứng với các user thích thể loại tương ứng, ta sẽ gợi ý bộ phim mới này cho các users.

Bảng 6.1: Ví dụ Utility matrix

	P1	P2	P3	P4
Nhiệm vụ bất khả thi	4	5	1	1
Avatar: Dòng chảy của nước	5	4		
La la land			4	5
Me before you	1	2	5	
Vệ binh dải ngân hà	4		2	3

Trong thực tế, số lượng users và items là rất lớn trong hệ thống, mỗi user thường đưa ra rất ít đánh giá về các items, thậm chí có những user không đánh giá bất kỳ một item nào (với những user này thì tốt nhất là gợi ý những bộ phim phổ biến nhất có nhiều người xem nhất). Vì vậy, số lượng ô trống trong ma trận là rất lớn, lượng ô có giá trị được điền chiếm tỉ lệ nhỏ. Một điều có thể thấy rõ là nếu càng nhiều ô có giá trị được điền thì độ chính xác của hệ khuyến nghị sẽ càng được cải thiện. Vì vậy, các hệ thống luôn hỏi người dùng về sự quan tâm của họ tới sản phẩm, dịch vụ và muốn người dùng đánh giá càng nhiều sản phẩm, dịch vụ càng tốt. Việc đánh giá này là rất quan trọng với các hệ khuyến nghị.

Không có Utility matrix, chỉ có cách khuyến nghị các sản phẩm phổ biến nhất. Vì vậy, trong các hệ khuyến nghị, việc xây dựng Utility Matrix là rất cần thiết. Tuy nhiên, việc xây dựng ma trận này thường có gặp nhiều khó khăn. Có hai hướng tiếp cận phổ biến để xác định giá trị rating cho mỗi vị trí trong Utility Matrix

- Nhờ người dùng đánh giá càng nhiều càng tốt
- Dựa vào hành vi của người dùng để điền thêm vào các vị trí chưa có ratings. Dựa vào những dữ liệu trong quá khứ của người dùng để dự đoán ra các giá trị này. Việc người dùng ở lại với nền tảng càng lâu sẽ tạo ra càng nhiều những thông tin hữu ích để dự đoán ra ratings của người dùng cho các sản phẩm, dịch vụ.

6.2.2 Hồ sơ của sản phẩm (item profiles)

Trong các hệ thống khuyến nghị dựa trên nội dung (nội dung của các sản phẩm), cần xây dựng một bộ hồ sơ của từng sản phẩm. Hồ sơ này được biểu diễn dưới dạng một vector đặc trưng. Trong các trường hợp đơn giản, đặc trưng này có thể được

Bảng 6.2: Xây dựng item profile

	P1	P2	P3	P4	film's feature vector
Nhiệm vụ bất khả thi	4	5	1	1	$\mathbf{x}_1 = [0.99, 0.02, 0.5]$
Avatar: Dòng chảy của nước	5	4			$\mathbf{x}_2 = [0.99, 0.1, 0.4]$
La la land			4	5	$\mathbf{x}_3 = [0.02, 0.98, 0.4]$
Me before you	1	2	5		$\mathbf{x}_4 = [0.01, 0.99, 0.6]$
Vệ binh dải ngân hà	4		2	3	$\mathbf{x}_5 = [0.99, 0.2, 0.9]$

trích xuất ra từ bản thân của sản phẩm. Ví dụ các đặc trưng của một bộ phim có thể được sử dụng như diễn viên, đạo diễn, năm phát hành, thể loại, quốc gia. Có rất nhiều yếu tố khác dùng để mô tả chính xác bộ phim cũng có thể được sử dụng. Việc chọn lựa được một bộ đặc trưng tốt cho các items là điều quan trọng dẫn đến sự hiệu quả của mô hình gợi ý. Một bộ đặc trưng tốt là bộ đặc trưng có thể mô tả chính xác được các items. Trong ví dụ đơn giản trong bảng 1 phía trên, chúng ta đơn giản hóa bằng cách xây dựng một vector đặc trưng ba chiều cho mỗi bộ phim: chiều thứ nhất là mức độ *hành động*, chiều thứ hai là mức độ *tình cảm*, chiều thứ ba là mức độ *hài hước*. Đặt các vector đặc trưng cho các bộ phim là $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5$. Giả sử có được giá trị của các vector đặc trưng cho các bài hát ở hình bên dưới. Nhiệm vụ là đi tìm từng mô hình người dùng θ_i để tối ưu hóa trên những ratings đã có trong bảng.

Bài toán đi tìm mô hình θ_i cho mỗi user có thể được coi là bài toán *hồi quy* trong trường hợp ratings là một dải giá trị, hoặc bài toán *phân loại* trong trường hợp ratings là một vài trường hợp cụ thể. Dữ liệu huấn luyện để xây dựng các mô hình θ_i là các cặp (feature vector, ratings) tương ứng với các items mà user đó đã có đánh giá. Việc điền các giá trị còn thiếu trong ma trận là các đầu ra cho các item chưa có đánh giá khi áp dụng mô hình θ_i .

6.2.3 Xây dựng hàm mất mát

Giả sử số users là N , số items là M , ma trận utility là $\mathbf{Y}$. Phần tử ở hàng m , cột n trong ma trận $\mathbf{Y}$ thể hiện mức độ quan tâm (rating) mà user thứ n đánh giá cho sản phẩm thứ m . Ma trận $\mathbf{R}$ thể hiện rằng một sản phẩm có được đánh giá bởi user tương ứng hay không. $r_{ij} = 1$ nếu item thứ i được đánh giá bởi user thứ j , ngược lại $r_{ij} = 0$.

Giả sử mỗi user có thể tìm được một mô hình θ_i được minh họa bởi vector cột hệ

số w_i và độ lệch b_n . Từ đó, mức độ quan tâm của user tới một item có thể được tính bằng một hàm tuyến tính:

$$y_{mn} = x_m w_n + b_n \quad (6.1)$$

Với x_m là vector đặc trưng - vector hàng, w_n là vector cột.

Với một user thứ n bất kỳ, ta có tập hợp các thành phần đã được đánh giá tương ứng của y_n , hàm mất mát có thể được xây dựng như sau:

$$\mathcal{L}_n = \frac{1}{2} \sum_{m:r_{mn}=1} (x_m w_n + b_n - y_{mn})^2 + \frac{\lambda}{2} \|w_n\|_2^2 \quad (6.2)$$

Trong đó, thành phần thứ hai là regularization để ngăn cho mô hình không bị overfit. Thông thường hàm mất mát sẽ được tính trên trung bình cộng của tất cả các vị trí có đánh giá của *user* nên hàm mất mát $\mathcal{L}_n$ được viết lại như sau:

$$\mathcal{L}_n = \frac{1}{2s_n} \sum_{m:r_{mn}=1} (x_m w_n + b_n - y_{mn})^2 + \frac{\lambda}{2s_n} \|w_n\|_2^2 \quad (6.3)$$

Trong đó s_n là số lượng các *items* mà *user* thứ n đã đánh giá.

Vì hàm mất mát chỉ được tính toán dựa trên các *items* đã được đánh giá nên có thể rút gọn lại hàm mất mát này bằng cách trích xuất vector cột $\hat{y}_n$ từ vector y . vector cột $\hat{y}_n$ chỉ chứa các phần tử có giá trị được đánh giá trong ma trận utility. Đồng thời, $\hat{X}_n$ là ma trận được trích xuất tương tự như vector $\hat{y}_n$. Khi đó, hàm mất mát được viết lại như sau:

$$\mathcal{L}_n = \frac{1}{2s_n} \|\hat{X}_n w_n + b_n e_n - \hat{y}_n\|_2^2 + \frac{\lambda}{2s_n} \|w_n\|_2^2 \quad (6.4)$$

Trong đó, e_n là vector cột chứa s_n phần tử 1. Cặp nghiệm w_n, b_n tương ứng với mô hình được tìm ra bằng việc áp dụng các phương pháp lan truyền ngược như Gradient Descent (GD), Stochastic Gradient Descent (SGD).

6.2.4 Ví dụ hàm mất mát cho user P2

Quay trở lại với ví dụ về đánh giá các bộ phim của một tập đối tượng người dùng trong Bảng 6.2 ma trận đặc trưng cho các items là:

$$X = \begin{bmatrix} 0.99 & 0.02 & 0.5 \\ 0.99 & 0.1 & 0.4 \\ 0.02 & 0.98 & 0.4 \\ 0.01 & 0.99 & 0.6 \\ 0.99 & 0.2 & 0.9 \end{bmatrix} \quad (6.5)$$

Với user P2 ở cột thứ $n = 2$, $\mathbf{y}_2 = [5, 4, *, 2, *]^T$ với các vị trí trong $\mathbf{y}_2$ có dấu "*" là những bộ phim mà người dùng P2 chưa có đánh giá. Vì người dùng P2 chỉ đánh giá cho bộ phim thứ 1,2,4 nên ta có thể viết rút gọn lại ma trận đặc trưng cho người dùng P2 này như sau:

$$\hat{\mathbf{X}}_2 = \begin{bmatrix} 0.99 & 0.02 & 0.5 \\ 0.99 & 0.1 & 0.4 \\ 0.01 & 0.99 & 0.6 \end{bmatrix}, \hat{\mathbf{y}}_2 = \begin{bmatrix} 5 \\ 4 \\ 2 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad (6.6)$$

Khi đó, hàm mất mát cho hệ số tương ứng với người dùng P2 sẽ được viết lại như sau:

$$\mathcal{L}_2 = \frac{1}{6} \left\| \begin{bmatrix} 0.99 & 0.02 & 0.5 \\ 0.99 & 0.1 & 0.4 \\ 0.01 & 0.99 & 0.6 \end{bmatrix} \mathbf{w}_2 + \mathbf{b}_2 - \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 5 \\ 4 \\ 2 \end{bmatrix} \right\|_2^2 + \frac{\lambda}{6} \|\mathbf{w}_2\|_2^2 \quad (6.7)$$

Trong thực tế, khi xây dựng các mô hình gợi ý sử dụng các ngôn ngữ như *python*, *C++*, chúng ta có thể sử dụng các hàm có sẵn trong các thư viện để tiến hành huấn luyện cho các mô hình với từng người dùng như bên trên. Việc hiểu cách thức xây dựng hàm mất mát cũng như quá trình huấn luyện sẽ giúp cho người đọc có thể điều chỉnh các tham số một cách phù hợp.

Lọc dựa trên nội dung là phương pháp đơn giản để xây dựng các hệ gợi ý. Đặc điểm của phương pháp này là quá xây dựng các mô hình cho từng người dùng không phụ thuộc vào các người dùng khác. Việc xây dựng mô hình cho từng người dùng có thể được coi là bài toán hồi quy hoặc phân loại với dữ liệu huấn luyện là các cặp (hồ sơ item, đánh giá) mà người dùng đã đánh giá. Hồ sơ item không phụ thuộc vào người dùng, mà phụ thuộc vào các đặc điểm dùng để mô tả item hoặc cũng có thể được xác định bằng việc yêu cầu người dùng đưa thêm thông tin về item.

6.3 Lọc cộng tác

Trong phần trước, lọc dựa trên nội dung được xây dựng dựa trên các bản mô tả (đặc trưng) của items giúp hệ thống tiết kiệm bộ nhớ và tính toán. Tuy nhiên, phương pháp này có hai nhược điểm cơ bản. Thứ nhất, mô hình được xây dựng cho từng user và không tận dụng được thông tin của các user khác mặc dù những thông tin này rất hữu ích khi gợi ý item. Thứ hai, không phải lúc nào việc trích xuất đặc trưng cho các item cũng thực hiện được. Hơn nữa, việc yêu cầu user đưa ra các đánh

giá cụ thể để sử dụng làm đặc trưng cho các item rất khó thực hiện hoặc là dù có thực hiện được nhưng độ tin cậy sẽ không cao. Những nhược điểm này có thể được giải quyết bằng lọc cộng tác (Collaborative Filtering). Lọc cộng tác được xây dựng với ý tưởng là xác định mức độ quan tâm của một user tới một item dựa trên các users khác gần giống đặc điểm với user này. Việc xác định sự giống nhau giữa các users sẽ dựa trên mức độ quan tâm của các users và các items mà hệ thống đã ghi nhận.

Để xây dựng một hệ thống dựa trên lọc cộng tác, có hai câu hỏi cần phải trả lời:

- Làm thế nào xác định được sự giống nhau của các users.
- Khi đã xác định được các users gần giống nhau, làm sao dự đoán được mức độ quan tâm của một user lên một item.

Cách tiếp cận như bên trên được gọi là lọc cộng tác dựa trên người dùng (user-user collaborative filtering). Có một cách tiếp cận khác là đi tìm sự liên quan giữa các items sau đó gợi ý cho user những items tương tự với các items mà người dùng có mức độ quan tâm cao. Cách tiếp cận này được gọi là lọc cộng tác dựa trên sản phẩm (item-item collaborative filtering).

6.3.1 Lọc cộng tác dựa trên người dùng (user-user collaborative filtering)

Hàm tương tự (similarity functions)

Công việc quan trọng nhất với lọc cộng tác dựa trên người dùng là xác định được sự giống nhau giữa hai users. Dữ liệu thu thập được duy nhất là ma trận Utility $\mathbf{Y}$, nên sự giống nhau phải được xác định dựa trên các cột tương ứng với hai users trong ma trận. Xét ví dụ trong Bảng 6.3 ma trận $\mathbf{Y}$ được xây dựng dựa trên đánh giá của các users từ $\mathbf{u}_0$ đến $\mathbf{u}_5$ với items từ $\mathbf{i}_0$ tới $\mathbf{i}_5$. Mỗi phần tử trong ma trận này thể hiện số điểm mà mỗi user đánh giá cho item với giá trị cao hơn thể hiện mức độ quan tâm cao hơn. Các phần tử để trống giá trị thì hệ thống sẽ phải điền đầy đủ vào để gợi ý cho users. Đặt mức độ giống nhau của hai users $\mathbf{u}_i, \mathbf{u}_j$ là $\text{sim}(\mathbf{u}_i, \mathbf{u}_j)$

Dựa trên quan sát ma trận trong Bảng 6.3 các users u_0, u_1 thích các items i_0, i_1, i_2 và không thích các items i_3, i_4, i_5 . Điều ngược lại thì xảy ra ở các users còn lại. Vì vậy trong trường hợp này, một hàm tương tự tốt cần đảm bảo

Bảng 6.3: Utility matrix cho users từ u_0 đến u_5 đánh giá items từ i_0 tới i_5

	u_0	u_1	u_2	u_3	u_4	u_5
i_0	5	5	2	1	1	
i_1	3			0		
i_2		5	1		1	2
i_3	1	1	5	4	5	4
i_4	2	2	3			5
i_5	2	0	4	5		
$\bar{u}_j$	2.6	2.6	3	2.5	2.33	3.66

$$sim(\mathbf{u}_0, \mathbf{u}_1) > sim(\mathbf{u}_0, \mathbf{u}_i), \forall i > 1 \quad (6.8)$$

Từ đây, để xác định mức độ quan tâm của $\mathbf{u}_0$ lên i_2 , ta có thể dựa vào hành vi của user $\mathbf{u}_1$ lên item này. Trong trường hợp này, hệ thống đã ghi nhận đánh giá của user $\mathbf{u}_1$ cho sản phẩm này nên hệ thống có thể gợi ý sản phẩm này cho user $\mathbf{u}_0$.

Để đo được mức độ tương tự của hai users, các vector đặc trưng của người dùng thường được sử dụng, sau đó áp dụng một hàm số tính toán khoảng cách giữa các vector đặc trưng này. Cần lưu ý rằng việc xây dựng vector đặc trưng này khác so với việc xây dựng hồ sơ item (item profile) như trong phần lọc dựa trên nội dung. Vector đặc trưng cho user trong phần này được xây dựng chỉ dựa vào ma trận utility mà không dùng thông tin ngoài như item profile. Với mỗi một user, thông tin duy nhất chúng ta có được là các đánh giá của user đó lên các items được hệ thống ghi nhận, tương ứng với cột của user đó trong ma trận. Tuy nhiên, thường thì một cột dữ liệu sẽ bị mất mát thông tin khá nhiều do các vị trí bị thiếu dữ liệu. Để khắc phục chúng ta có thể dùng một số kỹ thuật để điền đầy vào các vị trí này các giá trị phù hợp để tính toán hàm tương tự. Các giá trị này được điền vào để tính toán giá trị hàm tương tự chứ không ảnh hưởng đến giá trị cuối cùng của các vị trí trong utility matrix mà hệ thống đang đi tìm.

Mỗi vị trí trống có thể được thay thế bằng một giá trị nào đó để hạn chế việc sai lệch quá nhiều. Trong phần này có thể sử dụng các kỹ thuật đã trình bày trong Chương 2 về xử lý giá trị bị thiếu. Một trong những cách làm tốt trong trường hợp này là điền đầy các giá trị thiếu bằng giá trị trung bình cộng của các giá trị trên cột tương ứng. Việc này tránh được sự sai lệch với các users quá khó tính hoặc quá dễ

Bảng 6.4: Utility matrix chuẩn hóa cho users từ u_0 đến u_5 đánh giá items từ i_0 tới i_5

	u_0	u_1	u_2	u_3	u_4	u_5
i_0	2.4	2.4	-1	-1.5	-1.33	0
i_1	0.4	0	0	-2.5	0	0
i_2	0	2.4	-2	0	-1.33	-1.66
i_3	-1.6	-1.6	2	1.5	2.67	0.34
i_4	-0.6	-2.6	0.0	0	0	1.34
i_5	-0.6	-2.6	1	2.5	0	0

tính, tức lúc nào cũng có những items mà user thích hơn so với các items khác.

Chuẩn hóa dữ liệu

Hàng cuối cùng trong Bảng 6.3 là giá trị trung bình của các đánh giá cho mỗi user. Giá trị cao tương ứng với các user dễ tính và ngược lại. Khi đó nếu tiếp tục trừ đi mỗi đánh giá trong Bảng giá trị này và thay các giá trị chưa biết bằng 0, ta sẽ được một ma trận utility được chuẩn hóa như trong Bảng 6.4. Tầm quan trọng của việc chuẩn hóa này đến từ những yếu tố sau đây:

- Việc trừ đi giá trị trung bình cộng khiến trong mỗi cột sẽ có giá trị dương và âm. Giá trị dương tương ứng với việc user thích item, giá trị âm tương ứng với việc user không thích item. Những giá trị bằng 0 tương ứng với việc chưa xác định được liệu user có thích item tương ứng hay không
- Về mặt kỹ thuật, số lượng chiều của ma trận rất lớn với hàng triệu users và items, nếu lưu trữ toàn bộ các giá trị này trong một ma trận có khả năng cao không đủ bộ nhớ. Dựa trên quan sát thấy rằng số lượng vị trí có đánh giá là rất ít so với những vị trí trong ma trận không có đánh giá. Có một cách hiệu quả hơn đó là chỉ lưu trữ những đánh giá với vị trí của chúng.

Sau khi đã chuẩn hóa dữ liệu như bên trên, một hàm số tương tự được sử dụng để tính toán mức độ tương tự của các user.

Hàm cosine

Đây là một trong những hàm số được sử dụng nhiều nhất. Công thức của hàm cosine như sau:

Bảng 6.5: Ma trận độ tương đồng của các users

	u_0	u_1	u_2	u_3	u_4	u_5
u_0	1	0.71792251	-0.6463947	-0.6796738	-0.7534643	-0.2057247
u_1	0.71792251	1	-0.782508	-0.5770733	-0.6210472	-0.7059547
u_2	-0.6463947	-0.782508	1	0.53687549	0.90337195	0.58553168
u_3	-0.6796738	-0.5770733	0.53687549	1	0.4455657	0.05725799
u_4	-0.7534643	-0.6210472	0.90337195	0.4455657	1	0.44158779
u_5	-0.2057247	-0.7059547	0.58553168	0.05725799	0.44158779	1

$$\text{cosine_similarity}(\mathbf{u}_1, \mathbf{u}_2) = \cos(\mathbf{u}_1, \mathbf{u}_2) = \frac{\mathbf{u}_1^T \mathbf{u}_2}{\|\mathbf{u}_1\|_2 \cdot \|\mathbf{u}_2\|_2} \quad (6.9)$$

Trong đó $\mathbf{u}_{1,2}$ là các vectors tương ứng với user 1,2 đã được chuẩn hóa ở bên trên. Mức độ tương tự của hai vector là một số trong đoạn $[-1,1]$. Giá trị bằng 1 thể hiện hai vector hoàn toàn tương tự nhau. Hàm số $\cos$ của một góc bằng 1 nghĩa là góc giữa hai vectors bằng 0, tức là một vector bằng tích của một số dương với vector còn lại. Giá trị $\cos$ bằng -1 thể hiện hai vector này hoàn toàn ngược nhau. Nghĩa là khi hai users có hành vi hoàn toàn ngược nhau thì độ tương đồng của hai vectors tương ứng là thấp nhất. Việc tính toán giá trị độ tương đồng của các user được thực hiện để xây dựng một ma trận vuông kích thước $n \times n$ với n là số lượng các users trong hệ thống như trong Bảng 6.5. Do tính chất của hàm số $\cos$ ma trận này sẽ là một ma trận đối xứng, các giá trị trên đường chéo sẽ bằng 1. Từ việc quan sát ma trận này, các users tương tự nhau sẽ được gom nhóm lại với nhau để hệ thống gợi ý các item cho các users này tương tự nhau.

Nhìn vào Bảng 6.5 có thể thấy u_0 gần với u_1 (độ giống nhau là dương). Hai người dùng này giống nhau cũng tương đối dễ hiểu vì hai người dùng này có xu hướng đánh giá giống nhau cho các items. Trong khi đó u_2 thì gần các users u_3, u_4 và u_5 và xa users u_0 và u_1 .

Dự đoán rating (đánh giá)

Việc xác định mức độ quan tâm của một user lên một item dựa trên các users gần nhất (neighbor users) này rất giống với thuật toán K láng giềng gần nhất (KNN). Khi làm việc với các bài toán cỡ lớn (dữ liệu lớn), thuật toán KNN cũng thường được sử dụng vì tính toán đơn giản. Việc dự đoán ratings không thể sử dụng trực tiếp KNN

mà sẽ cần một số bước trung gian. Tương tự như KNN, trong lọc cộng tác, các giá trị đánh giá bị thiếu được tính toán dự đoán thông qua k users gần nhất. Chỉ quan tâm đến các users đã đánh giá item đang xem xét. Dự đoán đánh giá thường được xác định là trung bình có trọng số của các đánh giá đã chuẩn hóa. Trong KNN trọng số dựa trên khoảng cách giữa các vector (là số không âm). Trong khi đó với lọc cộng tác, trọng số được tính dựa trên điểm giống nhau giữa các users (có thể là số âm). Công thức phổ biến để dự đoán rating của user u cho item i là

$$\hat{y}_{i,u} = \frac{\sum_{u_j \in \mathcal{N}(u,i)} \bar{y}_{i,u_j} \text{sim}(u, u_j)}{\sum_{u_j \in \mathcal{N}(u,i)} |\text{sim}(u, u_j)|} \quad (6.10)$$

(sự khác biệt so với trung bình có trọng số là mẫu số có sử dụng trị tuyệt đối để xử lý các số âm).

trong đó $\mathcal{N}(u, i)$ là tập hợp k users trong các users lân cận (có độ tương đồng cao nhất) của u mà đã đánh giá item i .

Một ví dụ về việc tính normalized rating của u_0 cho i_2 với số nearest neighbors là $k = 2$. Các bước thực hiện là:

- Xác định các users đã đánh giá i_2 , đó là u_1, u_2, u_4, u_5 .
- Xác định độ tương đồng của u_0 với các users này ta nhận được các giá trị 0.72, -0.64, -0.75, -0.2. Hai giá trị ($k=2$) lớn nhất là 0.72 và -0.2 tương ứng với u_1 và u_5 .
- Xác định ratings được chuẩn hóa của u_1 và u_5 cho i_2 , ta thu được hai giá trị lần lượt là 2.4 và -1.66.
- Dự đoán kết quả:

$$\hat{y}_{i_2, u_0} = \frac{0.72 \cdot 2.4 + (-0.2) \cdot (-1.66)}{0.72 + |-0.2|} \approx 2.23 \quad (6.11)$$

Việc quy đổi các giá trị ratings đã chuẩn hoá về thang 5 có thể được thực hiện bằng cách cộng các cột của ma trận sau khi dự đoán với giá trị rating trung bình của mỗi user như đã tính. Việc hệ thống quyết định gợi ý items nào cho mỗi user có thể được xác định bằng nhiều cách khác nhau. Có thể sắp xếp items chưa được đánh giá theo thứ tự từ lớn đến bé của các đánh giá được dự đoán thông qua phương pháp bên trên, hoặc chỉ chọn các items có normalized predicted ratings dương - tương ứng với việc user này có nhiều khả năng thích hơn.

6.3.2 Lọc cộng tác dựa trên sản phẩm (item-item collaborative filtering)

Một số hạn chế của User-user CF:

- Trên thực tế, số lượng users luôn lớn hơn số lượng items rất nhiều. Kéo theo đó là ma trận tương đồng là rất lớn với số phần tử phải lưu giữ là hơn 1 nửa của bình phương số lượng users (chú ý rằng ma trận này là đối xứng). Việc này, như đã đề cập ở trên, khiến cho việc lưu trữ ma trận này trong nhiều trường hợp là không khả thi.
- Ma trận Utility thường là rất thưa. Với số lượng users rất lớn so với số lượng items, rất nhiều cột của ma trận này sẽ rất thưa (ít giá trị), tức chỉ có một vài phần tử khác 0. Lý do là users thường không để lại đánh giá của mình khi sử dụng sản phẩm dịch vụ. Cũng chính vì việc này, một khi user đó thay đổi đánh giá hoặc đánh giá thêm items, trung bình cộng các ratings cũng như vector chuẩn hoá tương ứng với user này thay đổi nhiều. Kéo theo đó, việc tính toán ma trận tương đồng, vốn tốn nhiều bộ nhớ và thời gian, cũng cần được thực hiện lại.

Ngược lại, nếu chúng ta tính toán similarity giữa các items rồi recommend những items gần giống với item yêu thích của một user thì sẽ có những lợi ích sau:

- Vì số lượng items thường nhỏ hơn số lượng users, ma trận tương đồng trong trường hợp này cũng nhỏ hơn nhiều, thuận lợi cho việc lưu trữ và tính toán ở các bước sau.
- Vì số lượng phần tử đã biết trong Utility matrix là như nhau nhưng số hàng (items) ít hơn số cột (users), nên trung bình, mỗi hàng của ma trận này sẽ có nhiều phần tử đã biết hơn số phần tử đã biết trong mỗi cột. Việc này cũng dễ hiểu vì mỗi item có thể được đánh giá bởi nhiều users. Kéo theo đó, giá trị trung bình của mỗi hàng ít bị thay đổi hơn khi có thêm một vài đánh giá. Như vậy, việc cập nhật ma trận tương đồng có thể được thực hiện ít thường xuyên hơn.

Cách tiếp cận thứ hai này được gọi là Item-item Collaborative Filtering. Hướng tiếp cận này được sử dụng nhiều trong thực tế hơn. Quy trình dự đoán missing ratings cũng tương tự như trong User-user CF. Về mặt tính toán, Item-item CF có thể nhận

được từ User-user CF bằng cách chuyển vị (transpose) ma trận utility và coi như items đang rate users. Sau khi tính ra kết quả cuối cùng, ta lại chuyển vị một lần nữa để thu được kết quả.

6.4 Lọc cộng tác dựa trên phân rã ma trận (matrix factorization)

Nhắc lại rằng trong Content-based Recommendation Systems, mỗi item được mô tả bằng một vector $\mathbf{x}$ được gọi là item profile. Trong phương pháp này, ta cần tìm một vector hệ số $\mathbf{w}$ tương ứng với mỗi user sao cho rating đã biết mà user đó cho item xấp xỉ với:

$$y \approx \mathbf{xw} \quad (6.12)$$

Với cách làm trên, Utility Matrix $\mathbf{Y}$, giả sử đã được điền hết, sẽ xấp xỉ với:

với $\mathbf{M}$, $\mathbf{N}$ lần lượt là số items và số users.

Chú ý rằng, $\mathbf{x}$ được xây dựng dựa trên thông tin mô tả của item và quá trình xây dựng này độc lập với quá trình đi tìm hệ số phù hợp cho mỗi user. Như vậy, việc xây dựng item profile đóng vai trò rất quan trọng và có ảnh hưởng trực tiếp lên hiệu năng của mô hình. Thêm nữa, việc xây dựng từng mô hình riêng lẻ cho mỗi user dẫn đến kết quả chưa thực sự tốt vì không khai thác được đặc điểm của những users gần giống nhau.

Bây giờ, giả sử rằng ta không cần xây dựng từ trước các item profile $\mathbf{x}$ mà vector đặc trưng cho mỗi item này có thể được huấn luyện đồng thời với mô hình của mỗi user (ở đây là 1 vector hệ số). Điều này nghĩa là, biến số trong bài toán tối ưu là cả $\mathbf{X}$ và $\mathbf{W}$; trong đó, $\mathbf{X}$ là ma trận của toàn bộ item profiles, mỗi hàng tương ứng với 1 item, $\mathbf{W}$ là ma trận của toàn bộ user models, mỗi cột tương ứng với 1 user.

Với cách làm này, ta đang cố gắng xấp xỉ Utility Matrix $\mathbf{Y} \in \mathbb{R}^{M \times N}$ bằng tích của hai ma trận $\mathbf{X} \in \mathbb{R}^{M \times K}$ và $\mathbf{W} \in \mathbb{R}^{K \times N}$.

Thông thường, K được chọn là một số nhỏ hơn rất nhiều so với $\mathbf{M}$, $\mathbf{N}$. Khi đó, cả hai ma trận $\mathbf{X}$ và $\mathbf{W}$ đều có hạng (rank) không vượt quá K . Chính vì vậy, phương pháp này còn được gọi là Low-Rank Matrix Factorization. Có một vài điểm lưu ý ở đây:

- Ý tưởng chính đằng sau phân rã ma trận cho hệ khuyến nghị là tồn tại các

latent features (tính chất ẩn) mô tả sự liên quan giữa các items và users. Ví dụ với hệ thống gợi ý các bộ phim, tính chất ẩn có thể là hình sự, chính trị, hành động, hài, ...; cũng có thể là một sự kết hợp nào đó của các thể loại này; hoặc cũng có thể là bất cứ điều gì có ý nghĩa. Mỗi item sẽ mang tính chất ẩn ở một mức độ nào đó tương ứng với các hệ số trong vector $\mathbf{x}$ của nó, hệ số càng cao tương ứng với việc mang tính chất đó càng cao. Tương tự, mỗi user cũng sẽ có xu hướng thích những tính chất ẩn nào đó và được mô tả bởi các hệ số trong vector $\mathbf{w}$ của nó. Hệ số cao tương ứng với việc user thích các bộ phim có tính chất ẩn đó. Giá trị của biểu thức $\mathbf{xw}$ sẽ cao nếu các thành phần tương ứng của $\mathbf{x}$ và $\mathbf{w}$ đều cao. Điều này nghĩa là item mang các tính chất ẩn mà user thích, vậy thì nên gợi ý item này cho user đó.

- Phân rã ma trận được xếp vào loại cộng tác bởi vì cách đi tìm hàm mất mát. Về cơ bản, để tìm nghiệm của bài toán tối ưu, ta phải lần lượt đi tìm $\mathbf{X}$ và $\mathbf{W}$ khi thành phần còn lại được cố định. Như vậy, mỗi hàng của $\mathbf{X}$ sẽ phụ thuộc vào toàn bộ các cột của $\mathbf{W}$. Ngược lại, mỗi cột của $\mathbf{W}$ lại phụ thuộc vào toàn bộ các hàng của $\mathbf{X}$. Như vậy, có những mối quan hệ ràng buộc chằng chịt giữa các thành phần của hai ma trận trên. Tức chúng ta cần sử dụng thông tin của tất cả để suy ra tất cả. Vậy nên phương pháp này cũng được xếp vào hệ khuyến nghị dựa trên lọc cộng tác.
- Trong các bài toán thực tế, số lượng items M và số lượng users N thường rất lớn. Việc tìm ra các mô hình đơn giản giúp dự đoán đánh giá cần được thực hiện một cách nhanh nhất có thể. Lọc cộng tác dựa trên láng giềng gần không yêu cầu việc huấn luyện quá nhiều, nhưng trong quá trình dự đoán (inference), ta cần đi tìm độ tương đồng của user đang xét với toàn bộ các users còn lại rồi suy ra kết quả. Ngược lại, với phương pháp phân rã ma trận, việc huấn luyện có thể phức tạp hơn vì phải lặp đi lặp lại việc tối ưu một ma trận khi cố định ma trận còn lại, nhưng việc dự đoán đơn giản hơn vì ta chỉ cần lấy tích của hai vector $\mathbf{xw}$, mỗi vector có độ dài K là một số nhỏ hơn nhiều so với M, N . Vậy nên quá trình dự đoán không yêu cầu khả năng tính toán cao. Việc này khiến nó phù hợp với các mô hình có tập dữ liệu lớn.
- Thêm nữa, việc lưu trữ hai ma trận $\mathbf{X}$ và $\mathbf{W}$ yêu cầu lượng bộ nhớ nhỏ khi so với việc lưu toàn bộ ma trận độ tương đồng trong phương pháp lọc cộng tác

dựa trên láng giềng gần nhất. Cụ thể, ta cần bộ nhớ để chứa $K(M + N)$ phần tử thay vì lưu M^2 hoặc N^2 của ma trận độ tương đồng.

Bài tập Chương 6

Bài tập 6.1. Hệ thống gợi ý phim Việt Nam dựa trên nội dung:

Thông tin chi tiết về các bộ phim Việt Nam:

<i>Tên phim</i>	<i>Thể loại</i>	<i>Đạo diễn</i>	<i>Diễn viên</i>	<i>Mô tả</i>
<i>Em chưa 18</i>	Hài hước, Tình cảm	Lê Thanh Sơn	Kaity Nguyễn, Kiều Minh Tuấn	Câu chuyện tình yêu tuổi teen.
<i>Cô gái đến từ hôm qua</i>	Tâm lý, Tình cảm	Phan Gia Nhật Linh	Hoàng Yến, Jun Phạm	Cô gái từ tương lai thay đổi quá khứ
<i>Trạng Quỳnh</i>	Hài hước, Dân gian	Đức Thịnh	Trần Quốc Anh, Trần Thành	Cuộc phiêu lưu kỳ bí của Trạng Quỳnh.
<i>Lời nguyện huyết ngải</i>	Kinh dị, Giật gân	Bùi Thạc Chuyên	Yu Dương, Thành Lộc	Cuộc phiêu lưu đầy ám ảnh của ba sinh viên trường Đại học Y

Ma trận Rating từ người dùng:

<i>Người dùng</i>	<i>Em chưa 18</i>	<i>Cô gái đến từ hôm qua</i>	<i>Trạng Quỳnh</i>	<i>Lời nguyện huyết ngải</i>
<i>Người A</i>	5	4	5	4
<i>Người B</i>	4	5	3	5
<i>Người C</i>	3	5	0	3
<i>Người D</i>	5	3	4	2
<i>Người E</i>	4	4	3	5
<i>Người F</i>	?	?	?	?

Yêu cầu cụ thể:

- Xây dựng hệ thống khuyến nghị dựa trên nội dung sử dụng thông tin về thể loại phim, đạo diễn, diễn viên và mô tả của các bộ phim Việt Nam.
- Điền thông tin đánh giá từ người dùng F vào ma trận rating để có thể đưa ra gợi ý phim cho người dùng F.
- Tính toán sự tương đồng giữa các bộ phim dựa trên thông tin nội dung và đề xuất các bộ phim tương tự hoặc có liên quan dựa trên sở thích của người dùng.

- Gợi ý top (K) bộ phim tốt nhất cho người dùng F, với (K) là số lượng bộ phim cần được gợi ý.

Bài tập 6.2. Lọc cộng tác dựa trên người dùng (user-user collaborative filtering):

Bài toán: Hệ thống đề xuất sách cho người dùng dựa trên đánh giá của người dùng khác.

Thông tin sẵn có:

- Ma trận rating: Một bảng dữ liệu lưu trữ xếp hạng của các người dùng cho các sách khác nhau.
- Thông tin người dùng: Các thông tin về sở thích, tuổi, giới tính,... của từng người dùng.

Yêu cầu:

- Xác định sự tương đồng giữa người dùng: Tính toán độ tương tự giữa các người dùng dựa trên xếp hạng mà họ đã đưa ra cho các sách và thông tin cá nhân của họ.
- Dự đoán xếp hạng chưa được xác định: Sử dụng thông tin về độ tương đồng để dự đoán xếp hạng cho một sách cụ thể mà một người dùng chưa đánh giá.

Cụ thể có một số người dùng và ma trận rating của họ cho các cuốn sách như sau:

Ma trận Rating:

	Sách 1	Sách 2	Sách 3	Sách 4	Sách 5
<i>Người A</i>	4	5	-	2	3
<i>Người B</i>	-	5	4	3	-
<i>Người C</i>	4	-	3	-	5
<i>Người D</i>	3	2	5	4	-
<i>Người E</i>	-	3	-	5	4

Thông tin Người dùng:

	Sở thích	Tuổi	Giới tính
<i>Người A</i>	Khoa học	25	Nam
<i>Người B</i>	Trình thám	30	Nữ
<i>Người C</i>	Kinh doanh	28	Nam
<i>Người D</i>	Hài hước	22	Nữ
<i>Người E</i>	Khoa học	27	Nữ

1. Cần dự đoán xếp hạng mà Người A sẽ đánh giá cho Sách 3.
2. Tính toán độ tương tự giữa Người A và các người dùng khác bằng cách sử dụng thông tin về sở thích, tuổi, giới tính và/hoặc các thông tin cá nhân khác.

Bài tập 6.3. Lọc cộng tác dựa trên sản phẩm (item-item collaborative filtering):

Bài toán: Hệ thống đề xuất sản phẩm cho người dùng dựa trên đánh giá của sản phẩm tương tự.

Thông tin sẵn có:

- Ma trận rating: Một bảng dữ liệu lưu trữ xếp hạng của các người dùng cho các sản phẩm khác nhau.
- Thông tin sản phẩm: Các thông tin về loại sản phẩm, nhãn hiệu, đặc điểm,... của từng sản phẩm.

Yêu cầu:

- Xác định sự tương đồng giữa các sản phẩm: Tính toán độ tương tự giữa các sản phẩm dựa trên xếp hạng mà người dùng đã đưa ra cho chúng.
- Dự đoán xếp hạng chưa được xác định: Sử dụng thông tin về độ tương đồng để dự đoán xếp hạng cho một sản phẩm cụ thể mà một người dùng chưa đánh giá.

Cụ thể có một số sản phẩm và ma trận rating của người dùng cho các sản phẩm như sau:

Ma trận Rating:

	Sản phẩm1	Sản phẩm2	Sản phẩm3	Sản phẩm4	Sản phẩm5
Người A	5	4	-	2	3
Người B	-	3	5	4	-
Người C	3	2	5	4	-
Người D	4	-	3	-	5
Người E	3	-	5	4	-

Thông tin Sản phẩm:

	Loại	Nhãn hiệu	Đặc điểm
Sản phẩm 1	Điện tử	ABC Company	Màn hình lớn, Pin lâu
Sản phẩm 2	Thời trang	XYZ Brand	Chất liệu cao cấp, Hợp thời trang
Sản phẩm 3	Đồ gia dụng	LMN Corp.	Tiết kiệm năng lượng, Đa chức năng
Sản phẩm 4	Điện tử	PQR Inc.	Camera chất lượng cao, Bộ nhớ lớn
Sản phẩm 5	Thể thao	DEF Co.	Chịu nước, Đệm êm

1. Cần dự đoán xếp hạng mà Người D sẽ đánh giá cho Sản phẩm 2.
2. Tính toán độ tương tự giữa Sản phẩm 4 và các sản phẩm khác bằng cách sử dụng các phương pháp đo lường độ tương đồng

Bài tập 6.4. Các bài tập thảo luận: Lựa chọn các đề tài thảo luận dưới đây về Hệ khuyến nghị:

1. *Xây dựng Hệ thống Khuyến nghị Phim dựa trên Nội Dung:* Sử dụng thông tin về thể loại, diễn viên, đạo diễn và nội dung phim để đề xuất phim tương tự cho người dùng.
2. *Triển khai Lọc Cộng tác dựa trên Người Dùng trong Hệ thống Gợi Ý Phim:* Phân tích lịch sử xem phim và xếp hạng của người dùng để đề xuất phim mới dựa trên sở thích tương đồng.
3. *Phát triển Hệ thống Gợi Ý Sản Phẩm sử dụng Lọc dựa trên Ngữ Cảnh Thời Gian và Vị Trí:* Đề xuất phim hoặc sản phẩm dựa trên thời gian xem, vị trí địa lý và thông tin ngữ cảnh của người dùng.
4. *Áp Dụng Deep Learning trong Hệ thống Khuyến Nghị Phim:* Sử dụng mô hình Deep Learning để cải thiện độ chính xác và hiệu suất của hệ thống khuyến nghị phim.
5. *Xây Dựng Hệ Thống Khuyến Nghị Lai cho Ứng Dụng Mua Sắm Online:* Kết hợp khả năng đề xuất sản phẩm trong nhiều lĩnh vực, từ phim đến thời trang, điện tử, để cung cấp trải nghiệm mua sắm đa dạng.
6. *Làm Việc với Knowledge-Based Recommendations trong Lĩnh Vực Du Lịch:* Xây dựng hệ thống đề xuất điểm đến, tour du lịch và thông tin hữu ích dựa trên sở thích và kiến thức chuyên môn về du lịch.

7. *Lọc Dựa Trên Thói Quen Tiêu Dùng và Hành Vi Người Dùng*: Phát triển mô hình đề xuất phim hoặc sản phẩm dựa trên hành vi mua sắm, thói quen tiêu dùng và xu hướng của người dùng.
8. *Hệ Thống Khuyến Nghị Phim Đa Nền Tảng và Tích Hợp Dữ Liệu Đa Nguồn*: Xây dựng hệ thống đề xuất phim có khả năng hoạt động trên nhiều nền tảng khác nhau (web, di động) và tích hợp dữ liệu từ nhiều nguồn khác nhau.
9. *Lọc Dựa Trên Ngữ Cảnh Thời Gian Thực và Trạng Thái Tâm Trạng Của Người Dùng*: Đề xuất phim dựa trên ngữ cảnh thời gian thực, vị trí và trạng thái tâm trạng của người dùng để cung cấp trải nghiệm tùy chỉnh.
10. *Hệ Thống Khuyến Nghị Sản Phẩm Cho Người Dùng Mới Dựa Trên Thông Tin Mặc Định*: Nghiên cứu cách đề xuất phim hoặc sản phẩm cho người dùng mới bằng cách sử dụng thông tin mặc định hoặc thông tin tổng quát từ cơ sở dữ liệu.